



Architecture AVANT

MinIO + poste LLM



Architecture APRÈS

Objets OVH puis un b3-8 après gates

Rapport architecture et livraison — 10 août → 13 septembre 2026

Statut : rapport D8, **pas une facture fournisseur ni une preuve de déploiement des cibles**. Fenêtre America/Toronto : 2026-08-10T00:00:00-04:00 inclus à 2026-09-14T00:00:00-04:00 exclus, soit **35 jours / 840 heures**.

1. Jointure avec la période précédente

Le dernier rapport de coûts fusionné sur `origin/main`, `docs/reports/couts-2026-07-13_2026-08-09.md`, finit le **9 août**. Le présent rapport commence donc le **10 août**, sans trou ni recouvrement. Un brouillon hors main n'est pas utilisé comme précédent. Aucune facture externe plus récente n'est présente dans le dépôt; cette réserve n'empêche pas d'établir la jointure des rapports Git.

2. Architecture — AVANT / APRÈS

Le Focus HTML daté compare exactement deux vues principales : **Architecture AVANT** → **Architecture APRÈS**. Les deux graphes sont produits à partir des Mermaid commités sous deux formes : SVG rendu et SvelteFlow natif complet avec sous-flows `parentId`. Chaque nœud/boîte affiche une icône de service et sa provenance `radar-immobilier`, `geo`, `poc-k8s` ou externe; URL utilisateurs et SSO sont inclus. La version PDF copie les deux graphes natifs complets sur pages A3 paysage; quatre zones recouvrantes par graphe reprennent les mêmes sous-flows, icônes et labels `repo` : à taille lisible.

Vue	État au 13 septembre	Lecture
Architecture AVANT	API raw/documents MinIO, graphe OVH, LLM depuis poste	Capture de référence
Architecture APRÈS	RAW/DOCS OVH, refresh autonome, Immo+Geo sur un b3-8 existant	Cible non déployée; NO-GO actuel

Les faits de transition (RAW OVH actif, T1 arrêté avant le LLM, T2 préprod accepté et T2 production en cours) expliquent le delta dans le texte. Ils ne constituent pas un troisième graphe d'architecture.

3. Travaux réalisés et vérifiés dans la fenêtre

- Graphify **0.18.0** a été intégré dans le refresh Immo; **Luna high** est le modèle sélectionné.

- Une première validation Kubernetes a été exécutée. Elle a échoué **avant tout appel LLM** : l'objet d'entrée était `.html`, alors que le profil exige un PDF. Cela prouve le fail-closed d'entrée, pas un Signal ni T1 accepté.
- Le rôle RAW préprod a passé la parité et l'API a été rebound vers `PP-RAW-OVH` ; l'ancienne identité raw est fenced/recovery-only.
- T2 préprod est accepté : DOCS OVH contient exactement **59,017 objets / 12,534,514,457 octets**, manifeste canonique SHA-256 `52646a7b...0425`, avec **failed=0**. Le surplus MinIO préprod n'a pas été promu comme canonique.
- Le StatefulSet, Pod et Service MinIO, le PVC data de 40 Gi et six NetworkPolicies ont été retirés. Le PVC de migration/checkpoint reste; la consommation quota passe de 4 PVC/47 Gi à 3 PVC/7 Gi. API/MCP/UI restent 1/1.
- L'implémentation est poussée sur `chore/scw-final-sweep` à `2ccabfc8`, mais n'est pas encore sur `origin/main` dans ce snapshot.
- Les URL Immo prod/préprod, leurs issuers SSO et les responsabilités des trois repos sont conservés dans les vues de référence.

4. Travaux en cours — aucune anticipation comptée comme acquise

- T1 : corriger la sélection vers un PDF réel, atteindre Luna high, puis prouver Signal typé + PDF exact, jeu idempotent et schedule autonome.
- T2 production est en cours. La source SCW actuelle reste la **référence initiale exacte** et OVH production doit atteindre les mêmes **59,017 keys et hashes** déjà acceptés en préprod. Les 85,176 objets de surplus préprod sont non-canoniques et n'ont pas été migrés.
- La gate production reste indépendante : copie conditionnelle → égalité des comptes/keys/hashes → preuve de reprise → fence/rebind → retrait MinIO.
- SCW TEM reste en place jusqu'à validation de son remplacement.

5. Projection d'aboutissement

Préprod a atteint sa tranche T2. Après la gate production, les deux environnements porteront le corpus canonique DOCS dans OVH et aucun MinIO ne restera actif. Après T1, le refresh est autonome en K8s. T3 reste gated : les 4,095m/8,442 Mi de requests mesurés avant cleanup ne tenaient pas dans 1,840m/5,907.82 Mi allouables. La nouvelle base, dont préprod est maintenant à 3 PVC/7 Gi, doit être re-mesurée; une étape deux nœuds vérifiée précède tout essai un nœud.

6. Coûts — méthode conservée, résultat non forcé

Infrastructure

La seule projection facturable demandée est un **b3-8 BHS5** au tarif déjà observé de `0.082 CAD/h` :

$$1 \times 840 \text{ h} \times 0.082 \text{ CAD/h} = 68.88 \text{ CAD}.$$

Les coûts de deux ou trois nœuds observés sont des coûts plateforme pass-through/internes : ils sont explicitement exclus. Les 68.88 CAD sont une projection cible, pas une consommation fournisseur mesurée sur la fenêtre.

LLM

L'audit JSON parcourt les sessions locales sur les bornes exactes. Claude est dédoublonné par (fichier, message.id) , avec maximum composante par composante pour 20 divergences; Codex par signature exacte (sessionId, timestamp, usage) . Les dates sont ramenées en America/Toronto. La collecte a été figée le **2026-09-13T21:09:35.483Z** : les sessions du 13 postérieures à ce cutoff ne sont donc pas inventées, tandis que la projection infra couvre contractuellement les 840 heures complètes.

La méthode et les unités du rapport précédent sont conservées : pic capacité global glissant de sept jours par fournisseur; deux sièges Claude et un ChatGPT Pro à 200 USD/mois; USD → CAD 1.37; marge LLM ×1.15. La plateforme n'entre pas dans les numérateurs immo/geo.

Produit	Claude	Codex	Allocation CAD	Allocation avec marge ×1.15
immo	14,009,998,961	1,426,882,082	121.163246	139.337732
geo	11,194,704,885	1,376,664,354	97.284961	111.877705
immo + geo	25,204,703,846	2,803,546,436	218.448207	251.215438 CAD

Capacités retenues : Claude **15,138,897,392 tokens / 7 j** (30 août → 5 septembre, pic rafraîchi) et Codex **32,217,805,325 / 7 j** (4 → 10 mai, pic historique audité resté supérieur au pic courant).

Le résultat LLM n'est pas abaissé artificiellement. Par rapport au brouillon de 30 jours (214.743159 CAD), la fenêtre correcte de 35 jours donne 251.215438 CAD; le taux journalier passe de 7.1581 à **7.1776 CAD/j**, soit +0.27 %. L'écart absolu vient principalement des cinq jours réintégrés. Forcer une baisse serait contraire aux journaux mesurés.

La ratification de cette allocation LLM reste **ouverte et non critique**. Sans réponse propriétaire, le montant demeure indicatif et ne bloque ni le dossier d'architecture ni les gates T1–T3.

Synthèse indicative non ratifiée pour le LLM

Poste	Montant
Projection infra, un b3-8	68.880000 CAD
Allocation LLM immo+geo, non ratifiée	251.215438 CAD
Somme indicative	320.095438 CAD

7. Sources, incertitudes et rejeu


- Les tokens viennent de journaux locaux : l'allocation n'est pas une ligne de facture fournisseur. Les tarifs/change sont repris, pas re-mesurés.
- Le corpus de capacité historique Codex vient de l'audit dédoublonné du 11 septembre; la nouvelle fenêtre l'aurait remplacé si son pic avait été plus élevé. Claude a été rescanné sur toute la fenêtre.
- Les résultats runtime T1/T2 proviennent des branches de réalisation et des faits owner datés; aucune symétrie production non observée n'est inventée.

Rejeu documentaire et preuve :

```
make -f docs/architecture/focus/Makefile tokens test build browser clipboard  
ENV=test-architecture
```


Architecture AVANT · schéma complet

Vue SvelteFlow native intégrale · icônes, provenance `repo` : , relations et sous-flows imbriqués.




Architecture AVANT · partition · haut gauche

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance `repo :` , relations et sous-flows imbriqués.




Architecture AVANT · partition · haut droite

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance `repo :`, relations et sous-flows imbriqués.




Architecture AVANT · partition · bas gauche

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance repo : , relations et sous-flows imbriqués.




Architecture AVANT · partition · bas droite

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance repo : , relations et sous-flows imbriqués.




Architecture APRES · schéma complet

Vue SvelteFlow native intégrale · icônes, provenance `repo` : , relations et sous-flows imbriqués.




Architecture APRÈS · partition · haut gauche

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance repo : , relations et sous-flows imbriqués.




Architecture APRÈS · partition · haut droite

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance `repo :` , relations et sous-flows imbriqués.



Architecture APRÈS · partition · bas gauche

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance repo : , relations et sous-flows imbriqués.



Architecture APRÈS · partition · bas droite

Vue SvelteFlow native agrandie avec recouvrement central · icônes, provenance `repo` : , relations et sous-flows imbriqués.

