

Rapport benchmark v101b — modèles, coûts, sièges

Date de mesure : 17 septembre 2026 · corpus gelé : 100 documents municipaux · contrat : immo-pv-extraction-v9.

Résumé exécutif


Décision M1 : astra-low en production, repli gemini-low. astra-low est le seul bras à 100/100 acceptés et son F1 Oracle v2 pondéré est **0,584**. gemini-low est le repli disponible : 85/100 acceptés, F1 pondéré 0,441, API \$0,0376/doc et burn AI Pro mesuré.

Tableau complet unique

F1 macro sur acceptés Oracle v2; F1 × acceptance inclut les 100 documents. Docs/h = 3 600 / p50 à concurrence 1. Waterloo est exclue du macro-oracle.

Bras	État; acceptés/N	F1 v2	F1 × acc.	API/doc	USD siège/doc mesuré	Sièges / 1 000 docs/mois	Docs/h (c=1)	p50	p95	Échecs dernière tentative
gemini-low	completed; 85/100	0.518	0.441	\$0.0376	\$0.0013	1 (AI Pro; low)	235.9	15.3 s	37.0 s	profile:7 · provenance:8
gemini-medium	completed; 79/100	0.423	0.334	\$0.0539	N-A (burn low seul)	N-A	133.4	27.0 s	44.6 s	profile:12 · provenance:9
gemini-high	completed; 53/100	0.518	0.275	\$0.1123	N-A (burn low seul)	N-A	52.2	69.0 s	88.4 s	json:44 · profile:2 · provenance:1
luna-low	completed; 39/100	0.621	0.242	\$0.0095	\$1.7558	9	38.0	94.8 s	168.2 s	transport:2 · profile:50 · provenance:9
luna-medium	completed; 51/100	0.582	0.297	\$0.0117	\$1.9155	10	28.4	126.6 s	216.8 s	transport:2 · json:2 · profile:36 · provenance:9
luna-high	completed; 43/100	0.788	0.339	\$0.0199	\$2.1426	11	14.5	247.8 s	480.0 s	transport:13 · json:1 · profile:33 · provenance:10
luna-xhigh	completed; 47/100	0.236	0.111	\$0.0346	\$3.0146	16	7.5	480.0 s	900.0 s	transport:15 · profile:23 · provenance:15 · budget:22
gpt41	completed; 64/100	0.000	0.000	\$0.0542	N-A (Claude/API)	N-A	209.8	17.2 s	41.3 s	transport:3 · profile:16 · provenance:17
sonnet46-cloud-off	circuit-open; 32/56	N-A	N-A	\$0.1750	N-A (Claude/API)	N-A	56.1	64.1 s	146.8 s	transport:10 · profile:10 · provenance:4
sonnet46-cloud-low	circuit-open; 14/29	N-A	N-A	\$0.1478	N-A (Claude/API)	N-A	5106.4	0.7 s	93.7 s	transport:15
sonnet46-cloud-high	circuit-open; 0/15	N-A	N-A	N-A	N-A (Claude/API)	N-A	12720.8	0.3 s	0.4 s	transport:15
sonnet5-off	completed; 62/100	0.528	0.327	\$0.2307	N-A (Claude/API)	N-A	31.8	113.2 s	242.7 s	transport:1 · json:13 · profile:12 · provenance:12
sonnet5-low	completed; 58/100	0.512	0.297	\$0.1114	N-A (Claude/API)	N-A	94.7	38.0 s	71.2 s	json:2 · profile:18 · provenance:22
sonnet5-high	completed; 70/100	0.396	0.277	\$0.2295	N-A (Claude/API)	N-A	29.7	121.4 s	249.4 s	json:13 · profile:8 · provenance:9
opus5-off	completed; 68/100	0.690	0.470	\$0.6507	N-A (Claude/API)	N-A	21.6	167.0 s	279.0 s	json:24 · profile:4 · provenance:4
opus5-low	completed; 74/100	N-A	N-A	\$0.3976	N-A (Claude/API)	N-A	45.4	79.3 s	157.0 s	json:2 · profile:14 · provenance:10
opus5-high	completed; 63/100	N-A	N-A	\$0.6472	N-A (Claude/API)	N-A	22.8	158.0 s	276.8 s	json:24 · profile:6 · provenance:7
opus5-cli-off	unknown; 0/0	N-A	N-A	N-A	N-A (Claude/API)	N-A	N-A	N-A	N-A	—
sol-low	completed; 90/100	0.583	0.525	\$0.1967	\$1.8750	10	29.7	121.3 s	205.5 s	transport:2 · profile:1 · provenance:7
sol-medium	completed; 94/100	0.558	0.525	\$0.2686	\$2.2257	12	19.2	187.3 s	317.3 s	provenance:6
sol-high	completed; 83/100	0.505	0.419	\$0.3460	\$2.1865	11	13.5	266.9 s	480.0 s	transport:12 · provenance:5
sol-xhigh	completed; 85/100	0.517	0.439	\$0.5498	\$3.0629	16	8.7	416.1 s	878.9 s	transport:10 · provenance:5 · budget:20
astra-low	completed; 100/100	0.584	0.584	\$0.4072	\$1.7649	9	24.4	147.8 s	297.0 s	—
astra-medium	completed; 99/100	0.452	0.448	\$0.4689	\$1.8596	10	19.0	189.8 s	320.2 s	transport:1
astra-high	completed; 68/100	0.667	0.453	\$0.5896	\$1.2808	7	11.4	316.1 s	480.0 s	transport:32
astra-xhigh	circuit-open; 65/100	0.611	0.397	\$0.9929	\$1.7341	9	6.0	596.7 s	900.0 s	transport:33 · profile:1 · provenance:1
mistral-small4	completed; 40/100	0.250	0.100	\$0.0050	N-A (Claude/API)	N-A	226.7	15.9 s	63.0 s	transport:4 · profile:28 · provenance:28

Graphique décisionnel



Marqueurs pleins : API; marqueurs creux : siège mesuré/conditionnel. Axe x logarithmique; taille = docs/h à concurrence 1.

Coûts, sièges et méthode

Gemini AI Pro : burn contrôlé réel de 260 documents, 5 635 342 tokens et -7,58 points sur 10 080 min; gemini-low ≈ \$0,0014/doc. Codex/ChatGPT : mesure passive réelle de 12 points, 207 reçus et 6 348 891 tokens; dérivation par bras via tokens/doc, granularité 1 point ±8 %. Claude : N-A, burn après reset 22:10Z non disponible.

Juges aveugles

Terra direct API : **422/605** terminaux; accord Terra/oracle par bras non finalisable. Opus 4.6 : **en cours, 227/605**. Mise à jour à la fin des deux jeux. La décision M1 repose sur l'oracle v2 gelé.

Décision M1 et limites

Déployer astra-low sous gates existants; repli document par document gemini-low. CronJob production : Waterloo seule. Avant extension : preuve de signaux neufs par ville, stratégie multi-ville, revue volume/palier réel.