

Coûts — période 2026-06-19 → 2026-07-03 (15 j) — immo / geo / sentropic

Généré : 2026-07-03 (journée du 03/07 partielle). **Change** : USD→CAD 1,37 (*inféré*) · EUR→CAD 1,617 (*inféré, taux des rapports précédents*). Chiffres **mesurés** (sessions réelles ~/.claude + ~/.codex via agent-stats ; facturation SCW réelle via scw billing ; usage cluster via kubectl top) sauf mention *estimé*. Rapport de coûts **séparé** du rapport de livraison. Références méthode : agent-stats/docs/costs/costs-immo-2026-06-22.md , costs-geo-2026-06-22.md , costs-2026-06-14.md .

Résumé exécutif

Compte	LLM facturable (×1,15)	Infra k8s (part)	Total période	Part
immo	24,45 CAD	~6,6 CAD	~31,0 CAD	22,2 %
geo	30,59 CAD	~4,3 CAD	~34,9 CAD	25,0 %
sentropic	50,72 CAD	~22,9 CAD	~73,6 CAD	52,7 %
Total	105,76 CAD	~33,8 CAD	~139,6 CAD	100 %

- **LLM en baisse de ~29 %** vs la quinzaine précédente (105,76 vs 148,55 CAD) : sentropic –48 %, immo –43 %, geo ×3,7 (geo est le projet le plus actif de la période, cohérent avec l'acquisition zones/lots).
- **Infra** : première quinzaine où les 3 tenants sont chiffrés (les rapports précédents ne chiffreraient que immo). Le poste dominant est **sentropic** : File System RWX 93 Gi (11,2 CAD, facturé réel) + part nœuds.

1. Coûts TOKEN / agents LLM (mesurés, agent-stats)

Recette — reproductible

Job Node existant `packages/web/scripts/project-costs.mjs` (repo `agent-stats`, s'appuie sur `@sentropic/agent-stats-core.collect()`). Attribution par **repo** (`cwd /src/<repo>` + `repoUrl git`), qui capture les sessions déléguées/headless/flotte.

```
# depuis ~/src/agent-stats – un run par compte
REPOS=radar-immobilier SINCE=2026-05-04 UNTIL=2026-07-04 \
  WINDOWS=prev:2026-06-04..2026-06-18,cur:2026-06-19..2026-07-03 \
  node packages/web/scripts/project-costs.mjs
REPOS=geo,geo-quebec SINCE=... UNTIL=... node packages/web/scripts/project-costs.mjs
REPOS=sentropic,sent-tech,sent-tech-design-system,agent-stats,track,poc-k8s,h2a,harness,coordinate \
  SINCE=... UNTIL=... node packages/web/scripts/project-costs.mjs
```

- **Périmètre des comptes (tokens)** : immo = `radar-immobilier` ; geo = `geo` + `geo-quebec` ; sentropic = `sentropic` , `sent-tech` , `sent-tech-design-system` , `agent-stats` , `track` , `poc-k8s` (+ alias `h2a` / `harness` / `coordinate` , sans volume propre). Périmètre sentropic explicité ici car aucun rapport précédent ne le chiffrait.
- **Capacité** = pic de tokens sur fenêtre glissante 7 j des tokens GLOBAUX par fournisseur, mesurée sur 2026-05-04 → 2026-07-03 : **Claude 23,42 Md/sem · Codex 35,41 Md/sem** (identique aux 23,4/35,4 du rapport du 22/06).
- **Prorata réel** = `tokens_compte ÷ (capacité_pic7j × 15/7) × (forfait_mensuel × 15/30)`. Forfaits : 2× Claude Max ×20 @ 200 \$US (forfait-période 200 \$US) + 1× ChatGPT Pro @ 200 \$US (forfait-période 100 \$US). **Marge facturable ×1,15** (LLM uniquement).
- **Contrôle de reproduction** : la fenêtre 06-15→06-22 recalculée aujourd'hui redonne immo **17,62 CAD** (17,60 publié le 23/06) et geo **12,72 CAD** (12,72 publié) → méthode stable, écart ≤ 0,1 %.

Facture LLM — période 2026-06-19 → 2026-07-03 (15 j)

Compte	claude (part capacité)	codex (part)	prorata USD	prorata CAD	facturable ×1,15	temps interactif
immo	3,88 Md (7,7 %)	0,04 Md (0,05 %)	15,52	21,26	24,45 CAD	~0,2 h

Compte	claudé (part capacité)	codex (part)	prorata USD	prorata CAD	facturable ×1,15	temps interactif
geo	4,71 Md (9,4 %)	0,50 Md (0,66 %)	19,41	26,60	30,59 CAD	~0,7 h
sentropic	8,05 Md (16,0 %)	0,08 Md (0,11 %)	32,19	44,10	50,72 CAD	~0,6 h
Total	16,64 Md (33,2 %)	0,63 Md (0,8 %)	67,12	91,96	105,76 CAD	~1,5 h

Répartition LLM : immo 23,1 % · geo 28,9 % · **sentropic 48,0 %**.

Comparaison — quinzaine précédente 2026-06-04 → 2026-06-18 (15 j)

Compte	facturable P–1	facturable P	Δ
immo	43,24 CAD	24,45 CAD	–43 %
geo	8,24 CAD	30,59 CAD	×3,7
sentropic	97,07 CAD	50,72 CAD	–48 %
Total	148,55 CAD	105,76 CAD	–29 %

Lecture : bascule de l'effort de la plateforme (sentropic, gros pic début juin) vers **geo**, désormais le compte produit le plus consommateur ; immo passe en mode finition/livraison (codex quasi nul : 0,04 Md).

2. Coûts INFRA k8s (cluster SCW Kapsule partagé)

Sources (mesures du 2026-07-03)

- **Facturation réelle** : `scw billing consumption list project-id=<PoCs> billing-period=2026-06|2026-07` . Projet PoCs (le cluster + services associés) : **juin 407,81 €** (dont nœuds/instances « Compute » **247,93 €**) ; **juillet MTD 01→03 : 33,76 €** (dont nœuds 22,79 €).
- **Usage cluster** : `kubecttl top pods -A` (instantané 03/07) : cluster total **363 m CPU / 13,4 Gi RAM**.
- **PVC** : `kubecttl get pvc -A` ; tarifs SCW : block `sbs` 0,0949 €/Gi/mois, File System facturé réel.
- Les messages h2a de poc-k8s (`env:pock8s:radar-geo-costs`) sont **introuvables sur disque** (aucun `.h2a` dans poc-k8s, aucune occurrence de « radar-geo-costs ») → les chiffres ci-dessus sont pris **à la source** (billing + kubecttl), ce qui est plus fiable qu'un relais de message.

Coût des nœuds sur la période (15 j)

Nœuds période = juin Compute × 12/30 (*lissage mensuel, estimé*) + juillet MTD (réel) = 247,93 × 0,4 + 22,79 = **121,96 € ≈ 197 CAD**.

Contexte juin : le poste Compute inclut le nœud legacy **POP2-4C-16G (83,35 €)** du pool `burst-rwx` — pool dimensionné pour les volumes RWX, dont les consommateurs sont `sentropic-remote` (workspaces 93 Gi) et `h2a-mcp` ; en juin les sessions remote ont piné jusqu'à 5 nœuds (source : `poc-k8s/requests/matchid.md`). Le pool a depuis migré sur BASIC3-X2C-8G.

Clé de répartition entre tenants — la même méthode que les semaines précédentes, étendue aux 3 comptes

Clé = part d'usage réel CPU/MEM du namespace ÷ usage réel du cluster (méthode retenue le 14/06 pour immo, `infra.md` : l'alternative par requests réservés avait été écartée comme « sur-provisionnée »). Mesure instantanée `kubecttl top` du 03/07 (*proxy de la période, estimé — même pratique que la base du 14/06*) :

Tenant (namespaces)	CPU	part CPU	RAM	part RAM	clé (moyenne)
immo (<code>radar-immobilier</code>)	12 m	3,3 %	354 Mi	2,6 %	~2,9 %
geo (<code>geo</code>)	9 m	2,5 %	210 Mi	1,5 %	~2,0 %
sentropic (<code>sentropic</code> , <code>sentropic-preprod</code> , <code>sentropic-remote</code> , <code>h2a-mcp</code>)	25 m	6,9 %	644 Mi	4,7 %	~5,8 %

Tenant (namespaces)	CPU	part CPU	RAM	part RAM	clé (moyenne)
reste du cluster (matchid, surch, openerp, système...)	317 m	87,3 %	12,5 Gi	91,2 %	~89,3 %

Le reste (~89 %) est porté par les autres tenants du cluster partagé (matchid domine : 9,2 Gi RAM à lui seul) — hors périmètre des 3 comptes.

Facture infra par compte — période (part nœuds + stockage direct)

Compte	nœuds (clé × 121,96 €)	block direct (PVC × tarif ÷ 2)	File System / autres	total infra CAD
immo	3,60 € → 5,8 CAD	10 Gi → 0,47 € → 0,8 CAD	S3 négligeable	~6,6 CAD
geo	2,45 € → 4,0 CAD	5 Gi → 0,24 € → 0,4 CAD	—	~4,3 CAD
sentropic	7,07 € → 11,4 CAD	3 Gi → 0,14 € → 0,2 CAD	FS RWX 93 Gi : 6,93 € → 11,2 CAD (facturé réel : 13,44 € juin × 12/30 + 1,55 € juil)	~22,9 CAD
Total 3 comptes				~33,8 CAD

S3 du projet : 0,84 € (juin) + 0,86 € (juil MTD) au niveau projet entier → non réparti (< 2 CAD période, négligeable).

Sensibilité (borne haute sentropic, estimé) : si l'on impute le pool burst-rwx en **causalité** (il n'existe que pour les workspaces RWX sentropic-remote/h2a-mcp) plutôt qu'à l'usage CPU/MEM : POP2 83,35 € + X2C-8G 28,49 € (juin, ×12/30) + 8,47 € (juil) ≈ 53,2 € ≈ **86 CAD** de nœuds → sentropic infra ≈ **97 CAD** au lieu de 22,9. Cette borne sur-attribue (immo/geo tournent aussi sur ces nœuds) ; la clé officielle du rapport reste l'usage réel, cohérente avec les semaines précédentes.

3. Récapitulatif par compte × poste

Compte	LLM prorata	LLM facturable ×1,15	Infra k8s	Total période	Part du total
immo	21,26	24,45	~6,6	~31,0 CAD	22,2 %
geo	26,60	30,59	~4,3	~34,9 CAD	25,0 %
sentropic	44,10	50,72	~22,9	~73,6 CAD	52,7 %
Total	91,96	105,76	~33,8	~139,6 CAD	100 %

Comparaison à la période précédente (06-04→06-18) : **LLM –29 %** (148,55 → 105,76 CAD). L'infra n'est **pas comparable** : la quinzaine précédente, seul immo était chiffré (~2,4 CAD/15 j au run-rate du 14/06) ; geo et sentropic n'avaient jamais été mesurés. La hausse apparente immo (2,4 → 6,6 CAD) vient de la clé mesurée plus haute (2,9 % vs 1,5 % le 14/06) et d'une facture nœuds juin plus élevée (247,93 € vs run-rate ~138 €/mois estimé mi-juin).

4. Hypothèses & réserves (honnêteté des chiffres)

- Mesuré** : tokens (sessions réelles, job agent-stats), facturation SCW (billing juin + juillet MTD), usage cluster (kubectl top), PVC. **Estimé** : lissage juin ×12/30 (pas de granularité jour dans le billing), clé d'usage = instantané du 03/07 (proxy période), taux de change (USD→CAD 1,37 ; EUR→CAD 1,617, *inférés*, identiques aux rapports précédents).
- Journée du 03/07 partielle** (rapport généré le 03/07) : tokens et billing juillet légèrement sous-évalués.
- Périmètre sentropic** explicité pour la première fois (9 repos tokens ; 4 namespaces infra, mcp-wave exclu — outillage personnel). Aucun rapport antérieur ne chiffrait ce compte : la « part sentropic » des semaines passées n'existe pas comme référence.
- Marge ×1,15 sur le LLM uniquement**, infra sans marge — même convention que le rapport immo du 22/06.
- Double comptage inter-comptes possible** si une session a un cwd d'un compte et un repoUrl d'un autre (worktrees croisés) — effet faible, non quantifié.

6. Le pic de capacité 7 j (dénominateur du prorata) est mesuré sur 2026-05-04 → 2026-07-03 ; il reproduit exactement les valeurs du rapport du 22/06.
7. Les chiffres h2a poc-k8s (env:pock8s:radar-geo-costs) n'ont pas été retrouvés ; l'infra est chiffrée directement à la source (billing SCW + kubect!), périmètre projet SCW « PoCs » (le projet matchid — incl. l'instance dataprep 225 €/juin citée par le finops — est hors périmètre des 3 comptes).