

Coûts immo & geo — période 2026-06-19 → 2026-07-03 (15 j)

Généré : 2026-07-03 (journée du 03/07 partielle). **Change** : USD → CAD 1,37 (*inféré*) · EUR → CAD 1,617 (*inféré, taux des rapports précédents*). Chiffres **mesurés** (sessions réelles `~/.claude` + `~/.codex` via agent-stats ; facturation SCW réelle via `scw billing` ; usage cluster via `kubectl top`) sauf mention *estimé*. Rapport de coûts **séparé** du rapport de livraison. Le corps du rapport présente le **facturable immo + geo** ; les méthodes (clé de prorata, dérivation de la facture SCW, recette agent-stats, contexte plateforme partagée, comparaison P-1, hypothèses) sont en **annexe**.

Résumé exécutif — facturable immo + geo

Poste	immo	geo	immo + geo
(A) Infra k8s	~6,6 CAD	~4,3 CAD	~10,9 CAD
(B) Abonnements IA / LLM (facturable ×1,15)	24,45 CAD	30,59 CAD	55,04 CAD
Total période	~31,0 CAD	~34,9 CAD	~65,9 CAD

- **immo ≈ 31,0 CAD / 15 j** — LLM **-43 %** vs la quinzaine précédente (24,45 vs 43,24 CAD) : mode finition/livraison (codex quasi nul : 0,04 Md).
- **geo ≈ 34,9 CAD / 15 j** — LLM **×3,7** (30,59 vs 8,24 CAD) : projet le plus actif de la période, cohérent avec l'acquisition zones/lots.
- **Infra** : première quinzaine où l'infra k8s des deux produits est chiffrée (les rapports précédents ne chiffraient que immo).

1. (A) Coûts INFRA k8s (cluster SCW Kapsule partagé)

Facture infra par produit — période (part nœuds + stockage direct) :

Produit	nœuds (clé × 121,96 €)	block direct (PVC × tarif ÷ 2)	S3 / autres	total infra CAD
immo	3,60 € → 5,8 CAD	10 Gi → 0,47 € → 0,8 CAD	S3 négligeable	~6,6 CAD
geo	2,45 € → 4,0 CAD	5 Gi → 0,24 € → 0,4 CAD	—	~4,3 CAD
immo + geo				~10,9 CAD

S3 du projet : 0,84 € (juin) + 0,86 € (juil MTD) au niveau projet entier → non réparti (< 2 CAD période, négligeable).

La part de chaque produit est le prorata de son **usage réel mesuré** du cluster (clé `kubectl top` , annexe A.1) appliqué à la **facture SCW réelle** de la période (121,96 € de nœuds — dérivation en annexe A.2).

2. (B) Abonnements IA / agents LLM (mesurés, agent-stats)

Abonnements mutualisés : **2× Claude Max ×20 @ 200 \$US/mois + 1× ChatGPT Pro @ 200 \$US/mois**. La part de chaque compte est calculée **au prorata de son usage réel en tokens** rapporté à la capacité des forfaits (recette reproductible en annexe A.3). **Marge facturable ×1,15** (LLM uniquement).

Facture LLM — période 2026-06-19 → 2026-07-03 (15 j) :

Compte	claude (part capacité)	codex (part)	prorata USD	prorata CAD	facturable ×1,15	temps interactif
immo	3,88 Md (7,7 %)	0,04 Md (0,05 %)	15,52	21,26	24,45 CAD	~0,2 h
geo	4,71 Md (9,4 %)	0,50 Md (0,66 %)	19,41	26,60	30,59 CAD	~0,7 h
immo + geo	8,59 Md (17,1 %)	0,54 Md (0,71 %)	34,93	47,86	55,04 CAD	~0,9 h

3. Récapitulatif par produit × poste

Produit	(A) Infra k8s	(B) LLM prorata CAD	(B) LLM facturable ×1,15	Total période
immo	~6,6	21,26	24,45	~31,0 CAD
geo	~4,3	26,60	30,59	~34,9 CAD
immo + geo	~10,9	47,86	55,04	~65,9 CAD

Annexe — méthodes, clés de répartition et contexte

Cette annexe porte les **méthodes** : elle ne modifie aucun chiffre du corps du rapport. **Méthode de répartition** : les coûts partagés (abonnements IA mutualisés, cluster k8s) sont répartis **au prorata de l'usage réel mesuré des 3 comptes** (immo, geo, plateforme partagée sentropic). Seuls **immo** et **geo** sont des postes client ; la part plateforme partagée sert de contexte au prorata (A.4). Références méthode : `agent-stats/docs/costs/costs-immo-2026-06-22.md` , `costs-geo-2026-06-22.md` , `costs-2026-06-14.md` .

A.1 Clé de répartition infra — prorata d'usage réel des 3 comptes (kubectl top)

Clé = part d'usage réel CPU/MEM du namespace ÷ usage réel du cluster (méthode retenue le 14/06 pour immo, `infra.md` : l'alternative par requests réservés avait été écartée comme « sur-provisionnée »). Mesure instantanée `kubectl top` du 03/07 (*proxy de la période, estimé — même pratique que la base du 14/06*) :

Tenant (namespaces)	CPU	part CPU	RAM	part RAM	clé (moyenne)
immo (radar-immobilier)	12 m	3,3 %	354 Mi	2,6 %	~2,9 %
geo (geo)	9 m	2,5 %	210 Mi	1,5 %	~2,0 %
plateforme partagée (sentropic , sentropic-preprod , sentropic-remote , h2a-mcp)	25 m	6,9 %	644 Mi	4,7 %	~5,8 %
reste du cluster (matchid, surch, openerp, système...)	317 m	87,3 %	12,5 Gi	91,2 %	~89,3 %

Le reste (~89 %) est porté par les autres tenants du cluster partagé (matchid domine : 9,2 Gi RAM à lui seul) — hors périmètre des 3 comptes. Usage cluster total mesuré : **363 m CPU / 13,4 Gi RAM** (`kubectl top pods -A` , instantané 03/07).

A.2 Dérivation de la facture SCW (infra)

Sources (mesures du 2026-07-03) :

- **Facturation réelle** : `scw billing consumption list project-id=<PoCs> billing-period=2026-06|2026-07` . Projet PoCs (le cluster + services associés) : **juin 407,81 €** (dont nœuds/instances « Compute » **247,93 €**) ; **juillet MTD 01 → 03 : 33,76 €** (dont nœuds 22,79 €).
- **PVC** : `kubectl get pvc -A` ; tarifs SCW : block sbs 0,0949 €/Gi/mois, File System facturé réel.
- Les messages h2a de poc-k8s (`env:pock8s:radar-geo-costs`) sont **introuvables sur disque** (aucun `.h2a` dans poc-k8s, aucune occurrence de « radar-geo-costs ») → les chiffres ci-dessus sont pris **à la source** (billing + kubectl), ce qui est plus fiable qu'un relais de message.

Coût des nœuds sur la période (15 j) : nœuds période = juin Compute × 12/30 (*lissage mensuel, estimé*) + juillet MTD (réel) = 247,93 × 0,4 + 22,79 = **121,96 € ≈ 197 CAD**.

Contexte juin : le poste Compute inclut le nœud legacy **POP2-4C-16G (83,35 €)** du pool `burst-rwx` — pool dimensionné pour les volumes RWX, dont les consommateurs sont `sentropic-remote` (workspaces 93 Gi) et `h2a-mcp` ; en juin les sessions remote ont piné jusqu'à 5 nœuds (source : `poc-k8s/requests/matchid.md`). Le pool a depuis migré sur BASIC3-X2C-8G.

A.3 Recette LLM (agent-stats) — reproductible

Job Node existant `packages/web/scripts/project-costs.mjs` (repo `agent-stats` , s'appuie sur `@sentropic/agent-stats-core.collect()`). Attribution par **repo** (`cwd /src/<repo> + repoUrl git`), qui capture les sessions déléguées/headless/flotte.

```
# depuis ~/src/agent-stats – un run par compte
REPOS=radar-immobilier          SINCE=2026-05-04 UNTIL=2026-07-04 \
  WINDOWS=prev:2026-06-04..2026-06-18,cur:2026-06-19..2026-07-03 \
  node packages/web/scripts/project-costs.mjs
REPOS=geo,geo-quebec            SINCE=... UNTIL=... node packages/web/scripts/project-costs.mjs
```

```
REPOS=sentropic,sent-tech,sent-tech-design-system,agent-stats,track,poc-k8s,h2a,harness,coordinate \
SINCE=... UNTIL=... node packages/web/scripts/project-costs.mjs
```

- **Périmètre des comptes (tokens)** : immo = radar-immobilier ; geo = geo + geo-quebec ; plateforme partagée = sentropic , sent-tech , sent-tech-design-system , agent-stats , track , poc-k8s (+ alias h2a / harness / coordinate , sans volume propre).
- **Capacité** = pic de tokens sur fenêtre glissante 7 j des tokens GLOBAUX par fournisseur, mesurée sur 2026-05-04 → 2026-07-03 : **Claude 23,42 Md/sem · Codex 35,41 Md/sem** (identique aux 23,4/35,4 du rapport du 22/06).
- **Prorata réel** = $\text{tokens_compte} \div (\text{capacité_pic7j} \times 15/7) \times (\text{forfait_mensuel} \times 15/30)$.
Forfaits-période : 2× Claude Max ×20 → 200 \$US ; ChatGPT Pro → 100 \$US.
- **Contrôle de reproduction** : la fenêtre 06-15 → 06-22 recalculée aujourd'hui redonne immo **17,62 CAD** (17,60 publié le 23/06) et geo **12,72 CAD** (12,72 publié) → méthode stable, écart ≤ 0,1 %.

A.4 Contexte du prorata — plateforme partagée (sentropic), hors postes client

sentropic est l'outillage mutualisé (harness, agent-stats, track, h2a, design system, poc-k8s...) au service des deux produits. Ses coûts **ne sont pas des postes client** ; ils figurent ici parce que le prorata des coûts partagés exige de mesurer l'usage des **3 comptes** — sans ce dénominateur commun, les parts immo/geo seraient faussées.

Poste	part plateforme partagée
(A) Infra k8s	~22,9 CAD (nœuds 7,07 € → 11,4 CAD + block 0,2 CAD + FS RWX 93 Gi : 11,2 CAD , facturé réel : 13,44 € juin × 12/30 + 1,55 € juil)
(B) LLM facturable ×1,15	50,72 CAD (8,05 Md Claude, 16,0 % de capacité + 0,08 Md codex, 0,11 % ; prorata 32,19 USD → 44,10 CAD ; ~0,6 h interactif ; -48 % vs P-1 : 97,07 CAD)
Total période	~73,6 CAD

- Totaux toutes parts (3 comptes), en référence : **LLM 105,76 CAD · infra ~33,8 CAD · ~139,6 CAD** (LLM : 16,64 Md claudes, 33,2 % + 0,63 Md codex, 0,8 % ; prorata 67,12 USD → 91,96 CAD ; ~1,5 h interactif).
- Répartition de l'usage LLM entre les 3 comptes : immo 23,1 % · geo 28,9 % · plateforme partagée 48,0 %.
- **Périmètre tokens** (9 repos) et **infra** (4 namespaces, mcp-wave exclu — outillage personnel) explicités pour la première fois : aucun rapport précédent ne chiffrait ce compte.
- **Sensibilité (borne haute, estimé)** : si l'on impute le pool burst-rwx en **causalité** (il n'existe que pour les workspaces RWX sentropic-remote/h2a-mcp) plutôt qu'à l'usage CPU/MEM : POP2 83,35 € + X2C-8G 28,49 € (juin, ×12/30) + 8,47 € (juil) ≈ 53,2 € ≈ **86 CAD** de nœuds → infra plateforme ≈ **97 CAD** au lieu de 22,9. Cette borne sur-attribue (immo/geo tournent aussi sur ces nœuds) ; la clé officielle du rapport reste l'usage réel, cohérente avec les semaines précédentes — et elle est **neutre pour immo/geo** (leur part reste calculée sur leur propre usage).

A.5 Comparaison — quinzaine précédente 2026-06-04 → 2026-06-18 (15 j)

Compte	facturable P-1	facturable P	Δ
immo	43,24 CAD	24,45 CAD	-43 %
geo	8,24 CAD	30,59 CAD	×3,7
immo + geo	51,48 CAD	55,04 CAD	+7 %
plateforme partagée	97,07 CAD	50,72 CAD	-48 %
Total 3 comptes	148,55 CAD	105,76 CAD	-29 %

Lecture : l'enveloppe produit (immo + geo) est stable (+7 %), avec une bascule d'immo (finition/livraison) vers **geo**, désormais le produit le plus consommateur. L'effort plateforme (gros pic début juin) retombe de moitié, d'où le total toutes parts à -29 %.

L'infra n'est **pas comparable** à la quinzaine précédente : seul immo était alors chiffré (~2,4 CAD/15 j au run-rate du 14/06) ; geo n'avait jamais été mesuré. La hausse apparente immo (2,4 → 6,6 CAD) vient de la clé mesurée plus haute (2,9 % vs 1,5 % le 14/06) et d'une facture nœuds juin plus élevée (247,93 € vs run-rate ~138 €/mois estimé mi-juin).

A.6 Hypothèses & réserves (honnêteté des chiffres)

1. **Mesuré** : tokens (sessions réelles, job agent-stats), facturation SCW (billing juin + juillet MTD), usage cluster (kubectl top), PVC. **Estimé** : lissage juin ×12/30 (pas de granularité jour dans le billing), clé d'usage = instantané du 03/07 (proxy période), taux de change (USD → CAD 1,37 ; EUR → CAD 1,617, *inférés*, identiques aux rapports précédents).
2. **Journée du 03/07 partielle** (rapport généré le 03/07) : tokens et billing juillet légèrement sous-évalués.
3. **Périmètre plateforme partagée** explicité pour la première fois (9 repos tokens ; 4 namespaces infra). Aucun rapport antérieur ne chiffrait ce compte : sa « part » des semaines passées n'existe pas comme référence.
4. **Marge ×1,15 sur le LLM uniquement**, infra sans marge — même convention que le rapport immo du 22/06.
5. **Double comptage inter-comptes possible** si une session a un cwd d'un compte et un repoUrl d'un autre (worktrees croisés) — effet faible, non quantifié.
6. Le pic de capacité 7 j (dénominateur du prorata) est mesuré sur 2026-05-04 → 2026-07-03 ; il reproduit exactement les valeurs du rapport du 22/06.
7. Les chiffres h2a poc-k8s (env : poc-k8s : radar-geo-costs) n'ont pas été retrouvés ; l'infra est chiffrée directement à la source (billing SCW + kubectl), périmètre projet SCW « PoCs » (le projet `matchid` — incl. l'instance dataprep 225 €/juin citée par le finops — est hors périmètre des 3 comptes).