

Coûts immo & geo — 12 août → 10 septembre 2026

Période : 2026-08-12T00:00:00-04:00 → 2026-09-10T23:59:59-04:00 , soit 30 jours.
Établi le 11 septembre 2026 : montants en CAD, infrastructure et abonnements LLM séparés. Les coûts produits restent des allocations calculées, pas des lignes de facture fournisseur par tenant.

Résultat corrigé : 257,63 CAD pour immo + geo, contre 260,78 CAD dans la première version. Le dénominateur infrastructure couvrait déjà tout le cluster ; la correction principale vient du lissage de deux instantanés complets au lieu d'extrapoler un pic CPU préprod. Le dédoublement des messages Claude réduit fortement les volumes publiés, mais change peu le coût alloué parce qu'il réduit aussi le pic de capacité commun.

Résumé exécutif — ancien vs corrigé

Poste	immo — ancien	immo — corrigé	geo — ancien	geo — corrigé	Total ancien	Total corrigé
Infrastructure OVH [estimé]	40,27	36,74	5,82	6,15	46,08	42,89
Abonnements LLM, marge ×1,15	117,71	118,26	96,98	96,48	214,70	214,74
Total période	157,98	155,00	102,80	102,64	260,78	257,63 CAD

Les totaux sont calculés avant arrondi ; l'addition des cellules arrondies peut différer de 0,01 CAD.

- **Écart total : -3,15 CAD (-1,2 %).** L'infrastructure baisse de 3,19 CAD ; le LLM augmente de 0,04 CAD après correction des volumes et des pics.
- **Volumes LLM corrigés :** immo **12,37 Md tokens** au lieu de 32,21 Md ; geo **10,09 Md** au lieu de 26,54 Md.
- **Périmètre immo vérifié :** le calcul agent-stats ne contient que le dépôt radar-immobilier . geo et geo-quebec appartiennent au groupe geo ; les dépôts plateforme sont séparés.

1. Infrastructure Kubernetes OVH

1.1 Pool facturable de la période

Le pool nœuds OVH est proratisé à **129,631836 CAD** pour la fenêtre. Le relevé d'août expose 122,448322 CAD de nœuds b3-8 ; celui de septembre 53,798241 CAD, arrêté le 11 septembre à 15:00:13Z.

Composante	Calcul	Pool nœuds CAD
12 → 31 août, 20 jours	122,448322 × 20/31	78,998917
1 → 10 septembre, 10 jours	53,798241 × 10/10,625151192	50,632918
Pool période	somme avant arrondi	129,631836

Les services S3, registry, load balancers et fournisseurs de tuiles ne sont pas ventilés dans ce montant centré sur nœuds + PVC. Leur absence du tableau ne signifie pas un coût nul.

1.2 Vérification du dénominateur : tout le cluster

Deux exécutions bornées ont été contrôlées avec `kubectl top pods -A` — limite de 30 secondes et `--request-timeout=20s` . **Les deux dénominateurs contiennent les 22 namespaces retournés par le cluster, sans filtrage préalable par client.**

Groupe	Namespaces inclus dans le dénominateur
radar	radar-immobilier , radar-immobilier-preprod
geo	geo , geo-preprod
matchid	matchid-dev , matchid-prod
openerp	openerp-dev , openerp-prod

Groupe	Namespaces inclus dans le dénominateur
sentropic	sentropic , sentropic-preprod , sentropic-remote
autres tenants	h2a-mcp , mcp-wave , nc-fullstack , pokemon-cards , transpose-cv
plateforme cluster	cert-manager , keda , kube-system , nfs-server , sealed-secrets , traefik

Le soupçon d'un dénominateur limité à radar+geo n'est donc **pas confirmé** : matchid, openerp, sentropic et les autres workloads participaient déjà aux totaux de **319 mCPU / 6 021 MiB**, puis **259 mCPU / 6 024 MiB**.

1.3 Deux instantanés complets et clé retenue

La clé d'allocation reste $(\text{part CPU} + \text{part RAM}) / 2$. Le premier rapport extrapolait le premier relevé à tout le mois. Le second relevé, effectué environ trois heures plus tard, montre que radar préprod est passé de **86 à 42 mCPU**, tandis que sa RAM reste à **957 MiB**. Le premier relevé captait notamment MinIO à **76 mCPU**.

Mesure	Cluster CPU/RAM	Clé immo	Clé geo	Infra immo, nœuds+PVC	Infra geo, nœuds+PVC
Instantané initial	319 m / 6 021 MiB	28,7221 %	4,2424 %	40,27	5,82
Nouveau relevé borné	259 m / 6 024 MiB	23,2752 %	4,7608 %	33,21	6,49
Moyenne retenue [estimé]	deux dénominateurs complets	25,9986 %	4,5016 %	36,74	6,15

La moyenne simple des deux clés évite de choisir le relevé le plus favorable. Elle reste un proxy : faute de télémétrie mensuelle conservée, la fourchette observée est **33,21–40,27 CAD pour immo** et **5,82–6,49 CAD pour geo**. Les deux relevés du 11 septembre (15:14Z et 18:13Z) sont **postérieurs à la fin de fenêtre** (11 septembre 03:59:59Z) : ils servent de proxy, pas de mesure intra-période.

Décomposition prod / préprod de la clé immo. Le namespace radar-immobilier-preprod porte **21,43 points sur 28,72** au premier relevé et **16,05 points sur 23,28** au second, soit en moyenne **18,74 %** pour la préprod contre **7,26 %** pour la production seule (7,30 % puis 7,22 %). La production immo seule vaut donc $\approx 10,04 \text{ CAD}$ ($7,26 \% \times 129,63 + 0,63$ de PVC prod). Le rapport P-1 ne comptait aucune préprod (namespace créé le 16 août) : le passage de 8,94 à 36,74 CAD reflète l'inclusion de la préprod et le passage du pool de 2 nœuds (P-1) à 3 nœuds au relevé du 11 septembre, pas une dérive de la production. L'imputation de la préprod au poste immo est un **choix soumis à l'owner**, pas une mesure.

1.4 Stockage direct et allocation corrigée

Le tarif block utilisé est **0,000088 CAD/GiB·h**. Les PVC actuels sont connus ; leur historique de capacité n'est pas reconstitué heure par heure.

Produit / environnement	PVC retenus	Coût [estimé]
immo prod	MinIO 5 Gi + Postgres 5 Gi, 720 h	0,633600
immo préprod	MinIO 40 Gi + Postgres 5 Gi, 606,038889 h depuis le 16 août	2,399914
geo prod	PostGIS 5 Gi, 720 h	0,316800

Produit	Nœuds, clé moyenne $\times 129,631836$	Stockage direct	Infrastructure corrigée
immo	33,702491	3,033514	36,736005 CAD
geo	5,835546	0,316800	6,152346 CAD
immo + geo	39,538037	3,350314	42,888351 CAD

Le stockage immo peut être surestimé : les 40 GiB de MinIO préprod sont appliqués à toute sa durée dans la fenêtre alors que le journal mentionne des redimensionnements début septembre.

2. Abonnements IA et agents LLM

2.1 Périmètre, fenêtre et formule

La relance agent-stats utilise exactement :

- groupe **immo** : dépôt radar-immobilier seulement ;
- groupe **geo** : dépôts geo et geo-quebec ;
- groupe **plateforme** : séparé, donc non imputé à immo ou geo ;
- fenêtre courante : 12 août → 10 septembre inclus ; fenêtre précédente : 13 juillet → 9 août inclus ;
- horizon de capacité : 4 mai → 11 septembre ; pic glissant de sept jours calculé séparément pour Claude et Codex ;

- forfaits repris du rapport précédent : 2 sièges Claude à 200 USD/mois et 1 abonnement ChatGPT Pro à 200 USD/mois pour les sessions Codex, change 1,37 CAD/USD ; marge **×1,15 sur le LLM seulement**.

Les 16 009 fichiers indexés ont 16 009 chemins uniques. Aucun transcript ni aucune session n'est attribué simultanément aux groupes immo, geo et plateforme : **0 session croisée, 0 token croisé** (sortie de `month-token-audit.mjs` déposée sous `.remote/month-evidence/token-audit-scope.txt`).

2.2 Double comptage des messages Claude

Le parseur comptait une ligne `assistant` comme un tour. Dans les transcripts Claude, le même `message.id` peut être répété pour plusieurs blocs de contenu ou d'outil avec les mêmes compteurs d'usage. Le contrôle complet des 342 fichiers Claude donne :

Contrôle Claude	Valeur
Lignes parcourues	1 464 036
Enregistrements assistant avec usage	404 619
Messages uniques (fichier , message.id)	173 140
Enregistrements répétés retirés	231 479
Doublons avec usage divergent	27, valeur composante par composante maximale retenue
Lignes malformées	5, ignorées comme par le parseur courant

Le dédoublonnage s'effectue par couple `fichier + message.id`, ce qui évite de fusionner deux sessions différentes portant un identifiant semblable. Côté Codex, les identifiants de session de l'index sont uniques ; un contrôle des événements identiques réduit seulement le pic historique et le volume immo de façon marginale.

2.3 Volumes et pics corrigés

Groupe / capacité	Claude ancien	Claude corrigé	Codex ancien	Codex corrigé
Pic capacité 7 j	40 092 898 291	15 121 217 650	35 407 501 297	32 217 805 325
immo, période	31 943 473 332	12 098 039 262	268 382 392	268 072 226
geo, période	26 318 264 265	9 870 054 358	220 024 915	220 024 915

Le pic Claude reste placé sur **30 août → 5 septembre** après correction ; le pic Codex reste sur **4 → 10 mai**. La fenêtre du pic n'a donc pas été déplacée pour modifier l'allocation.

Produit	Volume total ancien	Volume total corrigé	Variation
immo	32,21 Md	12,37 Md	-61,6 %
geo	26,54 Md	10,09 Md	-62,0 %

2.4 Allocation LLM corrigée

L'allocation projette d'abord la capacité de la fenêtre (`pic 7 j × 30/7`), puis applique la part `tokens produit / capacité 30 j` au forfait mensuel, au change et à la marge. Comme le même défaut gonflait à la fois les numérateurs Claude et leur dénominateur commun, la chute des volumes ne produit pas une chute équivalente des dollars.

Produit	LLM ancien	LLM corrigé	Écart
immo	117,71	118,259451	+0,55
geo	96,98	96,483708	-0,50
immo + geo	214,70	214,743159 CAD	+0,04

La fenêtre précédente recalculée sur le corpus actuellement disponible vaut **113,436497 CAD**, soit 4,05 CAD/j contre 7,16 CAD/j sur la période courante : **+76,7 %**. La comparaison avec le montant P-1 publié de 172,65 CAD donne **+16,1 % par jour**. Cette divergence interdit de remplacer rétroactivement le rapport précédent sans ses journaux et règles de parsing d'origine.

3. Total facturable corrigé

Produit	Infrastructure [estimé]	LLM ×1,15	Total
immo	36,736005	118,259451	154,995456 CAD
geo	6,152346	96,483708	102,636054 CAD
immo + geo	42,888351	214,743159	257,631510 CAD

Le coût corrigé est donc **257,63 CAD**, soit **8,59 CAD/j** sur 30 jours.

4. Cause de l'écart et limites

1. **Le dénominateur cluster n'était pas incomplet.** Les anciens totaux incluait déjà radar, geo, matchid, openerp, sentropic, les autres tenants et les namespaces système.
2. **L'instantané initial sur-attribuait immo.** Radar préprod consommait 86 mCPU, dont 76 mCPU pour MinIO, contre 42 mCPU au second relevé. La moyenne des deux mesures complètes ramène la clé immo de 28,72 % à 26,00 %.
3. **La part geo remonte légèrement.** Sa consommation est stable alors que le total CPU cluster baisse ; sa clé moyenne passe de 4,24 % à 4,50 %.
4. **Les volumes Claude étaient comptés par enregistrement, pas par message unique.** Le dédoublonnage retire 231 479 répétitions. L'effet financier est faible parce que le pic de capacité commun était gonflé par le même mécanisme.
5. **L'infrastructure demeure estimée.** Deux instantanés du 11 septembre ne remplacent pas une série temporelle couvrant les 30 jours. La fourchette est publiée pour rendre cette incertitude visible.
6. **La reproduction historique reste non conforme.** Les journaux accessibles aujourd'hui ne reproduisent pas au seuil de 0,1 % les montants P-1 publiés ; les comparaisons à cette période sont donc signalées séparément.
7. **La préprod pèse plus que la prod dans l'infra immo.** Sur la clé moyenne de 26,00 %, la préprod en porte 18,74 points et la production 7,26 points ; immo prod seule ≈ 10,04 CAD. Le rapport P-1 ne comptait aucune préprod. L'imputation de la préprod au client est un choix à trancher par l'owner, pas une mesure.

Sources : relevés OVH d'août et septembre 2026 ; deux inventaires complets `kubectl top pods -A` bornés et leurs métadonnées sous `.remote/month-evidence/` ; inventaire PVC ; agent-stats relancé avec groupes et fenêtres explicites ; audit exhaustif des `message.id` Claude et contrôle des sessions Codex (`token-audit-scope.txt`). Aucun HTML/PDF n'est généré par cette révision.